

Bases de Datos II
Helena Vargas
II Sem 2025

Lectura 3: Vector database management systems: Fundamental concepts, use-cases, and current challenges

En términos simples, ¿Cuál es la principal diferencia entre las consultas en una base de datos de vectores y bases de datos relacionales?

Las bases de datos relacionales son estructuradas, mientras que los vectores son no estructurados. Los vectores son n-dimensionales, y pueden consistir de números naturales, reales o complejos, y cada número representa una característica particular. Estas características pueden ser tanto muy simples como complejas.

A diferencia de bases de datos relacionales, donde se realizan consultas para obtener datos exactos ordenados en filas y columnas, para realizar consultas en vectores hay que buscar vectores similares usando vectores de consulta, pero no es exacto. El sistema de control, DBMS, facilita el manejo de datos, liberando recursos para otros aspectos más críticos de las empresas, brindando características como control de acceso y transacciones, ayudando a la escalabilidad y optimización.

¿Cómo se diferencia la representación de datos en una base de datos de vectores con bases de datos SQL y NOSQL?

La diferencia en la representación de datos es que, en las bases de datos de vectores, la representación puede resultar difícil de comprender.

Las bases de datos de vectores, usualmente se usan para representar datos bidimensionales (Ejemplo: $k = [6, 7]$). Los datos bidimensionales pueden representar, muy comúnmente, coordenadas o calificaciones de shows, por mencionar algunas aplicaciones. También es común utilizar vectores tridimensionales para representar datos más complejos (Ejemplo: $a = [7, 1, 6]$) al añadir una tercera coordenada.

Estos vectores son sencillos de visualizar y son comprendidos fácilmente por humanos, pero también es posible crear vectores de mayores dimensiones que no son tan sencillos de comprender. Estos vectores se pueden utilizar para representar datos aún más complejos. Las bases de datos relacionales y NOSQL, en la mayoría de los casos representan los datos de una manera que sea legible por humanos y tienen un significado intuitivo.

¿Qué es un vector embedding o feature vector?

Usualmente se textos que son legibles para humanos son vectorizados, es decir, son transformados en un vector de muchas dimensiones, de manera que pueda reflejar relaciones o patrones. El vector resultante de este proceso es llamado un vector embedding o feature vector. Se suele guardar el id, la metadata y lo que el vector representa. Por ejemplo, se puede encontrar vector embedding cuando Youtube utiliza metadatos

como el usuario, el idioma de lectura, tiempo desde que se vio por última vez, proveyendo recomendaciones personalizadas.

Explique el concepto de similarity search.

El similarity search consiste de metodos de indexación que permiten una búsqueda exacta y rápida de vectores similares, es decir, vectores que se parecen a una consulta haciendo cálculos como la distancia Euclidiana, similitud de cosenos, producto punto, o similitud de Jaccard. Se pueden utilizar diferentes métodos dependiendo del contexto y las características de los datos. Esta es una técnica muy usada en aplicaciones donde se buscan imágenes o texto similares.

Explique los diferentes use cases para los que se pueden usar bases de datos de vectores

- **Similarity search de imagen y video:** Es más complejo hacer la búsqueda, ya que hay que normalizar las imágenes debido al tamaño y los valores de los pixeles, y determinar las características antes de la vectorización. Usualmente se pasan las imágenes por una red neuronal, que cada vez obtiene características más específicas y abstractas de la imagen.
- **Reconocimiento de voz:** Es similar a la vectorización de videos. Si el audio está en forma analógica, se digitaliza y se divide en frames, que representan segmentos del audio. Estos segmentos son normalizados y transformados, y finalmente se almacenan como un vector. El audio completo es una secuencia de vectores. Al reconocer la voz, se pueden usar redes neuronales para reconocer y clasificar palabras y responder adecuadamente.
- **Chatbots y memoria duradera:** Los vectores se pueden utilizar para crear memoria a largo plazo para chatbots y IAs generativas. Los modelos generativos todavía tienen muchas limitaciones a la hora de recordar conversaciones pasadas o el contexto de la conversación. No tienen memorias de interacciones pasadas, y solo construyen las respuestas basándose en el input actual. Además, son entrenadas en grandes bases de datos, pero no logran distinguir los hechos y las interacciones con el usuario. Esto causa que los modelos puedan tener información errónea.