


Apuntes de Clase


En esta clase se explico el proyecto 2, por lo tanto se hara un resumen sobre esta evaluación

- La parte 1 del proyecto es construir un **dataset**, este va a estar basado en un sitio de e-commerce.
- Se va a usar algo llamado **selenium webdriver**, este es un software que simula acciones, por ejemplo abrir el navegador, buscar un sitio de comida y entrar a la pagina que salga. Uno debe especificarle cual es el driver que va a usar, osea el web driver. Por lo tanto, uno le debe de indicar la url, que buscar y que hacer.



- Por lo tanto con este selenium webdriver, vamos hacer que ingrese a una url y obtenga la informacion. Y con esa información es con la que se va a realizar nuestro dataset. Hay que elegir bien la pagina, ya que algunas tiene mayor seguridad y de vez en cuando mandan **captcha**, esto es justo un mecanismo de seguridad que los sitios web usan para verificar que quien interactúa con ellos es un humano y no un bot.
- Este proceso se llama **web scraping**, toda esta informacion la vamos almacenar en el bucket que se trabajo en el proyecto 1
- Luego con un controller listamos los datos desde el bucket y los mandamos uno por uno a una coleccion a MongoDB Atlas. Se debe de verificar, si el dato ya existe o si esta distinto al anterior.
- Se debe utilizar un **parser** de html en python para procesarlo con el titulo, características y así. A esto se le llama extraer los datos
- Una vez que se parsearon todos los html, se guardan como JSON en el PVC

- Luego usamos **spaCy**, este es un modelo de procesamiento de texto. Se va a procesar un texto y va a obtener una descripción de cada palabra que proceso. Con esta información aumentamos aun más los datos. Esto lo guardamos tambien en el PVC



- Luego con Spark normalizamos esta información
- En Mongo al **Atlas Search** le debemos crear un mapping
- Para la generacion del sitio web, tenemos permiso a utilizar **Inteligencia Artificial**, pero con la condición de explicar los prompts y documentar bien el código
- Se va a usar **Vercel**, ya que es muy facil su uso mediante github ya que es muy facil desplegarlo y los cambios se hacen automatico con los push en github
- Se debe usar **React, Vite y TailwindCSS** para la creacion de la UI
- Se va a usar **Firebase** para el manejo de los usuarios

Firebase

Core Features



Firebase ML



Hosting



Cloud Firestore



Cloud Storage



Cloud Functions



Test Lab



Authentication



Realtime Database

- Se va a necesitar una API, para algunas llamadas que se deben de realizar. Esta se va hacer en **NodeJS**
- Toda este web, debe ser pública, es decir debe estar desplegada y poder ser accedida desde un link

