

Lectura 3 - Vector database management systems: Fundamental concepts, use-cases, and current challenges

Estudiante: Priscilla Romero Barquero

Carné: 2023332718

1. En términos simples, ¿cuál es la principal diferencia entre las consultas en una base de datos de vectores y bases de datos relacionales?

Las consultas en las bases de datos relacionales se hacen con valores exactos o condiciones lógicas, algo como "Dame todas las compras del usuario X". En cambio en las bases de datos de vectores las consultas se hacen buscando una similitud entre vectores y no precisamente coincidencias exactas, algo así como "Dame las imágenes más parecidas a esta foto".

2. ¿Cómo se diferencia la representación de datos en una base de datos de vectores con bases de datos SQL y NoSQL?

Las bases de datos de vectores son utilizadas para representar datos complejos como textos, imágenes, audio y video. Estos datos son representados como vectores de alta dimensión y así pueden tener miles o millones de dimensiones lo que hace que sea inviable la visualización y los datos ilegibles para las personas.

Las bases de datos relacionales y NoSQL son diferentes porque los datos son números, cadenas de texto y tiempo que pueden ser legibles para las personas, por ejemplo en las bases de datos relaciones es mucho más fácil porque los datos se interpretan mediante nombre de tablas y columnas y en las NoSQL los datos pueden estar un poco desorganizados pero siguen siendo mucho más comprensibles que los vectores.

3. ¿Qué es un vector embedding o feature vector?

Cuando los datos legibles que procesan las bases de datos de vectores como textos, imágenes, audios, etc. se vectorizan, es decir se convierten en representaciones vectoriales de alta dimensión que captan sus patrones o relaciones más significativas, producen un vector, y estos son llamados embedding vector o feature vector.

4. Explique el concepto de similarity search.

Similarity search permite búsquedas rápidas y precisas de vectores similares. Consisten en buscar vectores que tengan un gran parecido a vectores que se dan de consulta basándose en métricas de distancia específicas. Estos son realmente útiles cuando se necesita buscar vectores similares al recuperar texto o imágenes.

5. Explique los diferentes use cases para los que se pueden utilizar bases de datos de vectores.

- Similarity Search

La mayoría de datos que puedan vectorizarse se puede utilizar similarity search, ya que es la base para realizar recuperación de bases de datos vectoriales.

- Image and video similarity search

Se utiliza en las imágenes, suele ser un proceso complejo porque implica la normalización de la imagen en términos de tamaño y valores de píxel, así como la extracción de características antes de la vectorización, este proceso se hace por medio de una red neuronal. Este proceso permite que se obtengan características más abstractas de la imagen como sus bordes y formas para ya después vectorizarlas y utilizar similarity search para su consulta. Para los videos, estos suelen descomponerse en fotogramas individuales, de igual manera se extraen sus características y se vectorizan en un vector de características que representa su contenido. También se incluye la información temporal para comprender mejor el contenido del video que analiza la secuencia de los hechos, produciendo una secuencia de vectores llamado tensor tridimensional que representan fotogramas, características y tiempo.

- Voice recognition

Los audios tienen un proceso similar al del video, se digitalizan y se dividen en fotogramas cortos, cada uno de los cuales representa un segmento del audio. Se normalizan, filtran y transforman para después almacenarse como un feature vector.

Estos vectores pueden utilizarse en autenticación, comparando una frase hablada vectorizada con grabaciones previas vectorizadas. También en asistentes conversacionales donde la voz vectorizada sirve como entrada para redes neuronales que reconozcan y clasifiquen palabras habladas y respondan en consecuencia en texto o voz sintetizada.

- Chatbots and long-term memory

Los VDBM pueden utilizarse para la memoria a largo plazo de chatbots u otros modelos generativos. Este tipo de interacciones tienen muchos problemas, como recordar conversaciones, contextos pasados, consideran una cantidad limitada de texto, etc. Entonces las bases de datos de vectores pueden ayudar a resolver un poco estos problemas almacenando e indexando vectores.

Cuando el usuario solicita algo al chatbot, este utiliza la consulta en lenguaje natural, la vectoriza y se usa como vector de consulta para una base de datos de vectores de memoria a largo plazo para encontrar las conversaciones similares, después el chatbot genera una respuesta, que se inserta en la base de datos de memoria a largo plazo en formato vectorizado y en lenguaje natural, y se devuelve al usuario. Al utilizar este enfoque permite recordar conversaciones pasadas, brindar info personalizada, codificación de secuencia de conversaciones y marcas de tiempo, reducción del uso de recursos computacionales.