

L3 - Vector database management systems: Fundamental concepts, use-cases, and current challenges

Estudiante: Carol Araya Conejo

Carnet: 2024089174

1. En términos simples, ¿cuál es la principal diferencia entre las consultas en una base de datos de vectores y bases de datos relacionales?

En una base de datos relacionales se busca coincidencias exactas en relación a los filtros definidos en el query; por otro lado, en una base de datos de vectores una consulta brinda una serie de características donde no se busca una coincidencia exacta, sino aquellas que tienen más similitudes con el vector de consulta.

2. ¿Cómo se diferencia la representación de datos en una base de datos de vectores con bases de datos SQL y NoSQL?

En una base de datos de vectores, se usan vectores de muchas dimensiones para representar datos complejos, por ejemplo texto, imágenes, audio, etc., y son difíciles de entender porque lo que se captura se usa para buscar similitud en objetos más que la lectura directa de los datos; por ello no tienen legibilidad para los humanos y no es viable de visualizar.

En una base de datos SQL su representación es más entendible para los humanos, pues la misma interpreta y almacena los datos por medio de tablas que tienen columnas y filas.

En las bases de datos NoSQL es más flexible pero menos estructurada como en la anterior y por ello es más difícil de comprender, aunque sus datos siguen siendo texto, números, documentos, etc., que pueden ser legibles para los humanos.

3. ¿Qué es un vector embedding o feature vector?

Un vector embedding o feature vector es el resultado de transformar datos legibles, como textos, imágenes, audio o video, en vectores de alta dimensión que capturan sus relaciones o patrones más importantes. Así, los datos complejos se convierten en números que representan sus características principales, lo que permite realizar búsquedas basadas en similitud en lugar de coincidencias exactas.

4. Explique el concepto de similarity search.

Este concepto es una funcionalidad de los VDBMS mediante la cual se puede encontrar vectores que se asemejen a un vector base dado en la consulta, basándose en métricas como distancia o alguna medida de similitud. Esto se realiza a través de métodos de indexación que permiten una búsqueda rápida y precisa de vectores similares a lo buscado.

5. Explique los diferentes use cases para los que se pueden utilizar bases de datos de vectores.

1. **Similarity search** Es utilizado para los objetos que pueden ser vectorizados de manera significativa y ser parte de una búsqueda aproximada de similitudes. Este uso es general para casi todas las operaciones.
2. **Image and video similarity search** Los datos multimedia pueden ser vectorizados; por ejemplo, en el caso de imágenes puede llegar a ser más complejo, ya que se tiene que normalizar en términos de píxeles y tamaño, además de la extracción de las características. Esta funcionalidad es externa y analiza las imágenes con una red neuronal. Dentro de las características extraídas van desde las más simples como bordes y formas hasta las más complejas como texturas, patrones, etc. Además, el proceso de búsqueda en similitud de imágenes se da a partir de una imagen como entrada. En el caso de los videos, estos son descompuestos en fotogramas y comparten un proceso similar de vectorización como el de las imágenes. Se incluye información temporal para poder distinguir el orden de los fotogramas y así tener contexto del video. La salida es una secuencia de vectores tridimensionales que representan los fotogramas.
3. **Voice Recognition** Este funciona similar a la vectorización y búsqueda de videos. El audio se divide en pequeños segmentos representados en frames. Cada frame se normaliza y se transforma en un feature vector, dando como resultado una secuencia de vectores que captura sus características.
 - Dentro de los usos principales se encuentra la autenticación de usuarios, por ejemplo, una clave hablada que se compara con otra que está vectorizada.
 - Así como el uso en agentes conversacionales, que pueden clasificar palabras recibidas como secuencias y, por medio de modelos, generar una respuesta.
4. **Chatbots and long-term memory** Los VDBMS se usan para mantener una memoria a largo plazo de los chatbots. Usan machine learning para generar un grado de comprensión del lenguaje general. Actualmente, los modelos generativos tienen limitaciones para recordar las conversaciones, así como límites de texto a recordar de forma detallada, lo que puede generar información inconsistente o incorrecta.

Para mitigar este problema se puede usar un VDBMS. Este funciona como memoria de largo plazo de un modelo generativo: al recibir un prompt del usuario, este es vectorizado y comparado con vectores que representan conversaciones similares. El modelo genera una respuesta que se almacena vectorizada en la base de datos y también se convierte a lenguaje natural para darle respuesta a la aplicación.

Beneficios:

- Recordar conversacion pasadas
 - Habilitar información personalizada
 - Codificar secuencias de conversacion con metadata y timestamps para dar un contexto
 - Reduccion de recursos computacionales ya que no se necesita entrenar el modelo de nuevo.
-