

L6 - Introduction to Apache Cassandra

Estudiante: Carol Araya Conejo

Carnet: 2024089174

Explique la arquitectura de Cassandra, puede apoyar su respuesta con otros recursos.

Tiene una arquitectura distribuida peer-to-peer, donde todos los nodos son iguales y no existe un nodo maestro. Esto elimina el riesgo de un single point of failure y facilita la escalabilidad horizontal.

Los nodos se comunican entre sí mediante el Gossip Protocol, que permite el intercambio de información sobre el estado del clúster. Los datos se organizan mediante un anillo de tokens (ring), que determina cómo se particionan y distribuyen los datos entre los nodos.

Esta arquitectura permite manejar grandes volúmenes de información (petabytes) y soportar miles de operaciones concurrentes por segundo, manteniendo una alta disponibilidad incluso ante fallos de nodos individuales.

¿Cómo funciona la replicación de Cassandra? ¿Cómo se diferencia de un esquema Master-Slave?

Cassandra distribuye los datos automáticamente entre los nodos del clúster y crea copias redundantes según el factor de replicación definido. Esto permite que, si un nodo falla, los datos sigan disponibles en otros nodos.

La configuración es simple: solo se indica cuántas copias se desean, y Cassandra se encarga del resto, incluso puede guardar datos en distintos racks o centros de datos.

A diferencia del modelo Master-Slave, en Cassandra no existe un nodo maestro; todos los nodos son iguales y pueden recibir lecturas y escrituras, evitando así un punto único de fallo y mejorando la disponibilidad.

¿Cómo afecta el modelo de replicación y de escritura la consistencia de datos?

En Cassandra, cualquier nodo puede recibir lecturas y escrituras, lo que permite un acceso totalmente distribuido. Los datos se escriben primero en un commit log (para asegurar durabilidad) y luego en memoria (memtable), antes de guardarse en disco (sstable). La consistencia es ajustable: el desarrollador puede definir cuántos nodos deben confirmar una operación para considerarla exitosa. Si se exige confirmación de todos los nodos, se obtiene mayor consistencia si basta con uno, se logra mayor disponibilidad. Aunque Cassandra no cumple completamente con ACID, sí garantiza que los datos sean atómicos, aislados y duraderos (AID), ofreciendo flexibilidad entre rendimiento y consistencia según cada operación.